

Statistiek college 5

Basis statistiek en betrouwbaarheidsintervallen

Marc Corstanje

13 April 2026

- Een stochast X is een willekeurig getal
- De verdeling van X beschrijft welke waarden X kan aannemen en wat de kansen daarop zijn
 - ▶ Deze verdeling kan discreet of continu zijn

Discrete verdeling

$$P(a \leq X \leq b) = \sum_{x=a}^b p(x)$$

Continue verdeling

$$P(a \leq X \leq b) = \int_a^b f(x) dx$$

Verwachtingswaarde

$$\mathbb{E}(X) = \begin{cases} \sum xp(x) & \text{als } X \text{ discreet} \\ \int xf(x) dx & \text{als } X \text{ continu} \end{cases}$$

Variantie

$$\mathbb{V}(X) = \mathbb{E}((X - \mathbb{E}(X))^2)$$

- 1 Enkele basisbegrippen uit de statistiek
- 2 Puntchatters (6.1)
- 3 Betrouwbaarheidsintervallen voor één steekproef (7.1 - 7.2)

1 Enkele basisbegrippen uit de statistiek

2 Puntchaters (6.1)

3 Betrouwbaarheidsintervallen voor één steekproef (7.1 - 7.2)

Voorbeeld (onzekerheidskwantificatie)

- **Vraag:** *Welke fractie van de Nederlanders was tégen de Coronamaatregelen?*
- **Waarnemingen:** Vraag 50 mensen, tel hoeveel er tégen zijn, en deel dit getal door 50 (geeft b.v. de schatting $15/50 = 0.30$).
- **Onzekerheid:** De geschatte fractie neemt bij herhaling telkens een andere waarde aan (0.30, 0.32, 0.27, 0.24, etc.)

Hoe kunnen we deze onzekerheid kwantificeren?

Basisaannames in statistiek

Data $x_1, \dots, x_n$ wordt gemodelleerd als uitkomsten van onafhankelijke stochasten $X_1, \dots, X_n$ met dezelfde verdeling f .


- $X_1, \dots, X_n$ noemen we een **aselecte steekproef** (random sample)
- n noemen we de **steekproefgrootte** (sample size)
- f noemen we de **onderliggende verdeling**

Trekkingen uit een populatie

- $X_1, \dots, X_n$ willekeurige trekkingen met teruglegging uit $\{y_1, \dots, y_N\}$.
- $\{y_1, \dots, y_N\}$ is de populatie
- N is de populatiegrootte (typische $N \gg n$).


De grote uitdaging in statistiek is het vinden van f door middel van $x_1, \dots, x_n$.

Een histogram van data $x_1, \dots, x_{1000}$



- De oppervlakte van een staaf is de proportie data die tussen de waarden op de x -as valt.
 - ▶ Een histogram is een goede benadering van de kansdichtheid!
- Deze data zou heel goed uit een normale verdeling kunnen komen. Wat is μ ? Wat is σ^2 ?

- Herinner: $\mu = \mathbb{E}(X)$. Probeer $\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i$?
- Herinner: $\sigma^2 = \mathbb{E}((X - \mu)^2)$. Probeer $\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \hat{\mu})^2$.



- 1 Enkele basisbegrippen uit de statistiek
- 2 Puntchatters (6.1)**
- 3 Betrouwbaarheidsintervallen voor één steekproef (7.1 - 7.2)

Onzekerheidskwantificatie (algemene aanpak)

- 1 Stel dat $f = f_\theta$.
- 2 Definieer een **puntschatter** $\hat{\theta} = \hat{\theta}(X)$ ("best guess") voor θ en bepaal de kansverdeling $f_{\hat{\theta}}$
- 3 Kwantificeer de onzekerheid in $\hat{\theta}$.

Voorbeeld

- $X_1, \dots, X_{50} \sim \text{Ber}(\theta)$ met onbekende fractie $0 \leq \theta \leq 1$.
 - ▶ Neem dan $\hat{\theta} = (X_1 + \dots + X_{50})/50$.
- Onzekerheid in $\hat{\theta}$?
 - ▶ $\mathbb{E}(\hat{\theta}) = \frac{1}{50} \sum_{i=1}^{50} \mathbb{E}(X_i) = \theta$
 - ▶ $\mathbb{V}(\hat{\theta}) = \frac{1}{50^2} \sum_{i=1}^{50} \mathbb{V}(X_i) = \frac{1}{50} \theta(1 - \theta)$

Voorbeeld: Wat is het gemiddelde gewicht van mensen uit Noord-Holland?

- **Waarnemingen:** $x_1, \dots, x_n$ (gewicht in kg).
- **Aselecte steekproef** $X_1, \dots, X_n \sim N(\mu, 10)$ met μ onbekend.
- **Puntschatter:** $\hat{\mu} = (X_1 + \dots + X_n)/n$.
- **Kansverdeling van de puntschatter:** $\hat{\mu} \sim N(\mu, 10/n)$.

Merk op dat $\mathbb{E}(\hat{\mu}) = \mu$. Zulke schatters noemen we *zuiver*

Voorbeelden van puntschatters

Stel $X_1, \dots, X_n$ een steekproef met verwachting μ en variantie σ^2 .

Puntschatter voor μ (steekproef gemiddelde)

- $\hat{\mu} = \bar{X} := \frac{1}{n} \sum_{i=1}^n X_i$

Puntschatter voor σ^2 (steekproef variantie)

- $\hat{\sigma}^2 = S^2$, waar $S^2 := \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$
- S heet de **steekproef standaard-deviatie** en is een schatter voor σ .

Merk op

- $\bar{X}$ en S^2 zijn **zuivere** schatters voor μ en σ^2
 - ▶ maar S is **niet** zuiver voor σ

- **Schatter:** $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$ is een *stochast*.
- **Schatting:** $\hat{\theta}(x_1, \dots, x_n)$ is een *getal*
- **Notatie:** $\bar{X}$ en S^2 voor schatters, $\bar{x}$ en s^2 voor schattingen.

Stelling

Gegeven $X_1, \dots, X_n$ onafhankelijk elk met verwachting μ en variantie σ^2 geldt

$$\mathbb{E}(\bar{X}) = \mu \quad \text{en} \quad \mathbb{V}(\bar{X}) = \frac{\sigma^2}{n}$$

Stelling

Als $X_1, \dots, X_n$ onafhankelijk $N(\mu, \sigma^2)$ -verdeeld zijn, geldt

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right) \quad \text{en} \quad Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

Stelling

Gegeven $X_1, \dots, X_n$ onafhankelijk elk met verwachting μ en variantie σ^2 geldt

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \rightarrow Z \quad \text{als } n \rightarrow \infty,$$

waar $Z \sim N(0, 1)$.


Een controle in Python

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import uniform, norm

n = 100
mu = 1/2
sigma = np.sqrt(1/12)

means = []
for i in range(10000):
    means.append(np.mean(uniform.rvs(size = n)))

xas = np.arange(start = 0.40, stop = 0.60, step = 0.002)
plt.hist(means, bins = 30, density = True)
plt.plot(xas, norm.pdf(xas, mu, sigma/np.sqrt(n)), color='red', linewidth=2)
plt.show()
```



- 1 Enkele basisbegrippen uit de statistiek
- 2 Puntchaters (6.1)
- 3 Betrouwbaarheidsintervallen voor één steekproef (7.1 - 7.2)**

Hoe goed is een schatter?

- We zien data
 - ▶ 5.648643, 4.293323, 4.686545, 4.896612, 4.332913, 5.056876, 5.253751, 4.833708, 4.973055, 5.044269
- We vermoeden $X_1, \dots, X_{10} \sim N(\mu, 1)$.
- We schatten μ met $\bar{x} = 4.90197$.
- Hoever zal dit van de daadwerkelijke μ af zitten?
- Kunnen we de onzekerheid kwantificeren?

Stelling

Stel $Z \sim N(0, 1)$.

- Herinner z_α is zodanig dat $P(z > z_\alpha) = \alpha$
- $z_\alpha = \text{norm.ppf}(1-\alpha)$
- Dus is $P(-z_{\alpha/2} \leq Z \leq z_{\alpha/2}) = 1 - \alpha$

Gevolg

Als $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$, dan.

$$P\left(\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha$$

Een betrouwbaarheidsinterval voor μ wanneer σ bekend is

Constructie

Zij $X_1, \dots, X_n$ een aselechte steekproef uit $N(\mu, \sigma^2)$ met σ bekend en μ onbekend.

Gezocht: Een interval $[A, B]$ zodat de kans dat μ erin zit 95% is.

- 1 Schat μ met $\bar{X}$.
- 2 De variantie van $\bar{X}$ geeft een onzekerheidsmarge.
- 3 Bekijk $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$.
- 4 Dus $P(z_{0.025} < Z < z_{0.975}) = 0.95$
- 5 Schrijf dit om naar $P\left(\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right) = 0.95$.

m.a.w. μ ligt met 95% zekerheid in het interval $\bar{X} \pm 1.96 \frac{\sigma}{\sqrt{n}}$.

Merk op: Als de steekproef niet normaal is, maar wel voldoende groot, is Z vanwege de CLT nog steeds $\approx N(0, 1)$ -verdeeld!


95% betrouwbaarheidsinterval voor μ (normale populatie met bekende σ)

Voorbeeld

- Construeer een 95% BTI voor de gemiddelde reactietijd van jong volwassenen.
- Gegeven is een steekproef van grootte $n = 25$ met $\bar{x} = 250\text{ms}$. Neem aan dat de reactietijden normaal verdeeld zijn met $\sigma = 20\text{ms}$.

Oplossing: $\bar{x} \pm 1.96\sigma/\sqrt{n} = 250 \pm 1.96 \times 4 \approx [242, 258]$.

- **Incorrecte interpretatie:** *“De kans dat μ in $[242, 258]$ zit, is 95%.”*
- **Correcte interpretatie:** *“Als het experiment herhaaldelijk wordt uitgevoerd, dan geldt naar verwachting dat in 95% van de experimenten $\mu \in [\bar{x} - 1.96\sigma/\sqrt{n}, \bar{x} + 1.96\sigma/\sqrt{n}]$.”*



Betrouwbaarheidsinterval voor μ bij bekende σ

- Een $100(1 - \alpha)\%$ BTI voor μ op basis van een aselechte steekproef van grootte n uit $N(\mu, \sigma^2)$ met bekende σ is $\bar{x} \pm z_{\alpha/2} \sigma / \sqrt{n}$.
 - ▶ $z_{\alpha/2} = \text{norm.ppf}(1 - \alpha/2)$.
- $100(1 - \alpha)$ heet het **betrouwbaarheidsniveau** van het interval.

Opmerking 1

De nauwkeurigheid van de puntschatting $\bar{x}$ wordt gekwantificeerd door de lengte $2z_{\alpha/2} \sigma / \sqrt{n}$ van het interval.

Opmerking 2

De lengte van het interval neemt toe met afnemende α en neemt af met toenemende n .

Betrouwbaarheidsinterval voor μ bij onbekende σ)

- **Vraag:** Wat als σ onbekend is?
- **Oplossing:** Vervang σ dan door

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2} = \text{np.std}(x, \text{ddof}=1)$$

- ▶ Neem eerst aan dat de populatie normaal is.
- ▶ Dan is


$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$$

- ▶ $t(n-1)$ de **t -verdeling met $n-1$ vrijheidsgraden** is.
- ▶ Er geldt dus dat $1 - \alpha = P(-t_{\alpha/2, n-1} < T < t_{\alpha/2, n-1})$.
 - ▶ $t_{\alpha/2, n-1} = \text{t.ppf}(1-\alpha/2, n-1)$.
- ▶ $\bar{x} \pm t_{\alpha/2, n-1} s / \sqrt{n}$ een $100(1 - \alpha)\%$ BTI is voor μ .

De t -verdeling

De t -verdeling $t(n)$ met n vrijheidsgraden is:

- Symmetrisch rond 0
- Lijkt op $N(0, 1)$ maar heeft “dikkere staarten”
- $t_{\alpha/2, n-1} > z_{\alpha/2}$, dus de BTI's zijn groter.
- Convergeert naar $N(0, 1)$ voor $n \rightarrow \infty$



Betrouwbaarheidsinterval voor de fractie p successen uit Bernoulli trials

- Zij $X_1, \dots, X_n \sim \text{Ber}(p)$, $p \in [0, 1]$ (dus $X_i \in \{0, 1\}$ voor $i = 1, \dots, n$).
 - ▶ $\mathbb{E}(\bar{X}) = p$ en $\mathbb{V}(\bar{X}) = p(1 - p)/n$

- Als n gróót ^a dan is

$$\hat{p} \pm z_{\alpha/2} \sqrt{\hat{p}(1 - \hat{p})/n}$$

een BTI voor p met een betrouwbaarheidsniveau van ongeveer $100(1 - \alpha)$.

^aVuistregel: $n\hat{p} \geq 10$ en $n(1 - \hat{p}) \geq 10$.

- Data $x_1, \dots, x_n$ zien we als onafhankelijke realisaties van stochasten $X_1, \dots, X_n$
- Parameters uit de onderliggende verdeling schatten we met **punteschatters**
 - ▶ Punt-schat-ter voor μ : het **steekproefgemiddelde** $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$
 - ▶ Punt-schat-ter voor σ^2 : de **steekproefvariantie** $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$
- **Betrouwbaarheidsintervallen voor μ** wanneer $\bar{X}$ normaal verdeeld
 - ▶ Als σ bekend $\bar{x} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$
 - ▶ Als σ onbekend $\bar{x} \pm t_{\alpha/2, n-1} \frac{s}{\sqrt{n}}$
- **Betrouwbaarheidsintervallen voor een populatiefractie p**
 - ▶ $\hat{p} \pm z_{\alpha/2} \sqrt{\hat{p}(1 - \hat{p})/n}$

Volgende les

- Hypothese toetsen