

Statistiek college 8

Gepaarde en ongepaarde steekproeven

Marc Corstanje

6 Mei

- 1 Inferentie voor twee onafhankelijke steekproeven (9.1 en 9.2)
- 2 Inferentie voor een gepaarde steekproef (9.3).

Wanneer $\bar{X}$ normaal verdeeld is, bekijken we

$$T = \frac{\bar{X} - \mathbb{E}(\bar{X})}{\sqrt{\mathbb{V}(\bar{X})}}$$

- Hier is $\mathbb{E}(\bar{X}) = \mu$ en $\mathbb{V}(\bar{X}) = \frac{\sigma^2}{n}$
- Als σ bekend, is $T \sim N(0, 1)$
- Als σ geschat wordt met S , is $T \sim t_{n-1}$

Dit gebruiken we voor

- Hypothese toetsen omtrent μ
- Betrouwbaarheidsintervallen voor μ

Wanneer verschillen twee datasets van elkaar?

Het statistische probleem: Kunnen we zeggen dat twee datasets significant van elkaar verschillen?

Voorbeelden

- Stemmen in Michigan méér mensen op Trump dan in Arizona?
- Werkt het door Janssen ontwikkelde corona vaccin?
- Krijgen vrouwen een láger salaris dan mannen voor vergelijkbare functies?
- Gaan laptops van Dell en Apple even lang mee?

- Twee sets data
 - ▶ $X_1, \dots, X_n$
 - ▶ $Y_1, \dots, Y_m$
- **Ongepaarde data:** De variabelen X_i en Y_j zijn onafhankelijk van elkaar.
- **Gepaarde data:** De variabelen zijn afhankelijk en kunnen gezien worden als paren (X_i, Y_i) , $i = 1, \dots, n$

Gepaarde data of ongepaarde data

- Twee sets data
 - ▶ $X_1, \dots, X_n$
 - ▶ $Y_1, \dots, Y_m$
- **Ongepaarde data:** De variabelen X_i en Y_j zijn onafhankelijk van elkaar.
- **Gepaarde data:** De variabelen zijn afhankelijk en kunnen gezien worden als paren (X_i, Y_i) , $i = 1, \dots, n$

Voorbeeld 1

Om te onderzoeken of het Janssen vaccin werkt, geven we een groep het vaccin en een andere groep een placebo.

? Gepaard of ongepaard?

Gepaarde data of ongepaarde data

- Twee sets data
 - ▶ $X_1, \dots, X_n$
 - ▶ $Y_1, \dots, Y_m$
- **Ongepaarde data:** De variabelen X_i en Y_j zijn onafhankelijk van elkaar.
- **Gepaarde data:** De variabelen zijn afhankelijk en kunnen gezien worden als paren (X_i, Y_i) , $i = 1, \dots, n$

Voorbeeld 1

Om te onderzoeken of het Janssen vaccin werkt, geven we een groep het vaccin en een andere groep een placebo.

? Gepaard of ongepaard?

Voorbeeld 2




Om te zien hoe goed een remsysteem in een auto werkt meten we bij 20 remmende auto's de snelheid op twee tijdstippen.

? Gepaard of ongepaard?

1 Inferentie voor twee onafhankelijke steekproeven (9.1 en 9.2)

2 Inferentie voor een gepaarde steekproef (9.3).

- Wanneer kunnen we zeggen dat dataset 1 en 2 wezenlijk van elkaar verschillen?



Zij $X_1, \dots, X_n$ en $Y_1, \dots, Y_m$ twee ongepaarde steekproeven met verwachtingen μ_1 en μ_2 en varianties σ_1^2 en σ_2^2 .

Zij $X_1, \dots, X_n$ en $Y_1, \dots, Y_m$ twee ongepaarde steekproeven met verwachtingen μ_1 en μ_2 en varianties σ_1^2 en σ_2^2 .

We gaan **toetsingsgrootheden** en **betrouwbaarheidsintervallen** construeren voor $\mu_1 - \mu_2$ voor de volgende drie scenario's:

- 1 Normale populaties met bekende varianties.
- 2 Normale populaties met onbekende varianties.
- 3 Algemene, maar grote populaties.

Vaste tactiek: Kijk hoeveel $\bar{X}$ en $\bar{Y}$ van elkaar verschillen

Scenario 1: Normale populaties met bekende varianties

Toets of er verschil tussen de data zit

$$H_0 : \mu_1 - \mu_2 = 0 \quad \text{tegen} \quad H_a : \mu_1 - \mu_2 \begin{matrix} < \\ \neq \\ > \end{matrix} 0$$

Merk op

Als $X \sim N(\mu_1, \sigma_1^2)$ en $Y \sim N(\mu_2, \sigma_2^2)$ onafhankelijk zijn, is

$$X - Y \sim N(\mu_1 - \mu_2, \sigma_1^2 + \sigma_2^2)$$

Dit passen we toe op $\bar{X}$ en $\bar{Y}$!

Scenario 1: Normale populaties met bekende varianties

Toets of er verschil tussen de data zit

$$H_0 : \mu_1 - \mu_2 = 0 \quad \text{tegen} \quad H_a : \mu_1 - \mu_2 \begin{matrix} < \\ \neq \\ > \end{matrix} 0$$

Merk op

Als $X \sim N(\mu_1, \sigma_1^2)$ en $Y \sim N(\mu_2, \sigma_2^2)$ onafhankelijk zijn, is

$$X - Y \sim N(\mu_1 - \mu_2, \sigma_1^2 + \sigma_2^2)$$

Dit passen we toe op $\bar{X}$ en $\bar{Y}$!

Toetsingsgrootheid

$$Z = \frac{\bar{X} - \bar{Y}}{\sqrt{\sigma_1^2/n + \sigma_2^2/m}} \sim N(0, 1) \text{ onder } H_0$$

De z -toets voor het verschil tussen normale populaties

- **Toetsingsgrootheid:**
$$Z = \frac{\bar{X} - \bar{Y}}{\sqrt{\sigma_1^2/n + \sigma_2^2/m}}$$
- **p -waarde:**
 - ▶ Als $H_a : \mu_1 - \mu_2 \neq 0$, dan $2(1 - \Phi(|z|)) = 2*(1 - \text{norm.cdf}(\text{np.abs}(z)))$
 - ▶ Als $H_a : \mu_1 - \mu_2 < 0$, dan $\Phi(z) = \text{norm.cdf}(z)$
 - ▶ Als $H_a : \mu_1 - \mu_2 > 0$, dan $1 - \Phi(z) = 1 - \text{norm.cdf}(z)$

Scenario 1: Normale populaties met bekende varianties

De z -toets voor het verschil tussen normale populaties

- **Toetsingsgrootheid:** $Z = \frac{\bar{X} - \bar{Y}}{\sqrt{\sigma_1^2/n + \sigma_2^2/m}}$
- **p -waarde:**
 - ▶ Als $H_a : \mu_1 - \mu_2 \neq 0$, dan $2(1 - \Phi(|z|)) = 2 * (1 - \text{norm.cdf}(\text{np.abs}(z)))$
 - ▶ Als $H_a : \mu_1 - \mu_2 < 0$, dan $\Phi(z) = \text{norm.cdf}(z)$
 - ▶ Als $H_a : \mu_1 - \mu_2 > 0$, dan $1 - \Phi(z) = 1 - \text{norm.cdf}(z)$

Betrouwbaarheidsinterval

Een $(1 - \alpha)100\%$ betrouwbaarheidsinterval voor $\mu_1 - \mu_2$ is

$$\bar{X} - \bar{Y} \pm z_{\alpha/2} \sqrt{\sigma_1^2/n + \sigma_2^2/m}$$

Verwerp ten faveure van $\mu_1 \neq \mu_2$ als deze 0 niet bevat!

Voorbeeld: Studie naar een nieuw griepsmedicijn

- Studiegroep (125) is gemiddeld na 3.5 dag beter
- Controlegroep (90) is gemiddeld na 4 dagen beter

Neem aan $\sigma_1^2 = 0.8$ en $\sigma_2^2 = 1$. Is het medicijn significant effectief?

Voorbeeld: Studie naar een nieuw griepsmedicijn

- Studiegroep (125) is gemiddeld na 3.5 dag beter
- Controlegroep (90) is gemiddeld na 4 dagen beter

Neem aan $\sigma_1^2 = 0.8$ en $\sigma_2^2 = 1$. Is het medicijn significant effectief?

① $H_0 : \mu_1 - \mu_2 = 0$ en $H_a : \mu_1 - \mu_2 < 0$.

Voorbeeld: Studie naar een nieuw griepsmedicijn

- Studiegroep (125) is gemiddeld na 3.5 dag beter
- Controlegroep (90) is gemiddeld na 4 dagen beter

Neem aan $\sigma_1^2 = 0.8$ en $\sigma_2^2 = 1$. Is het medicijn significant effectief?

❶ $H_0 : \mu_1 - \mu_2 = 0$ en $H_a : \mu_1 - \mu_2 < 0$.

❷

$$z = \frac{3.5 - 4}{\sqrt{0.8/125 + 1/90}} \approx -3.78$$

Voorbeeld: Studie naar een nieuw griepsmedicijn

- Studiegroep (125) is gemiddeld na 3.5 dag beter
- Controlegroep (90) is gemiddeld na 4 dagen beter

Neem aan $\sigma_1^2 = 0.8$ en $\sigma_2^2 = 1$. Is het medicijn significant effectief?

1 $H_0 : \mu_1 - \mu_2 = 0$ en $H_a : \mu_1 - \mu_2 < 0$.

2

$$z = \frac{3.5 - 4}{\sqrt{0.8/125 + 1/90}} \approx -3.78$$

3 $p\text{-waarde} = \text{norm.cdf}(-3.78) \approx 7.9 \cdot 10^{-5}$.

Voorbeeld: Studie naar een nieuw griepsmedicijn

- Studiegroep (125) is gemiddeld na 3.5 dag beter
- Controlegroep (90) is gemiddeld na 4 dagen beter

Neem aan $\sigma_1^2 = 0.8$ en $\sigma_2^2 = 1$. Is het medicijn significant effectief?

1 $H_0 : \mu_1 - \mu_2 = 0$ en $H_a : \mu_1 - \mu_2 < 0$.

2

$$z = \frac{3.5 - 4}{\sqrt{0.8/125 + 1/90}} \approx -3.78$$

3 $p\text{-waarde} = \text{norm.cdf}(-3.78) \approx 7.9 \cdot 10^{-5}$.

4 Ja, het nieuwe medicijn is significant beter.

Scenario 2: Normale populaties met onbekende varianties

$$H_0 : \mu_1 - \mu_2 = 0 \quad \text{tegen} \quad H_a : \mu_1 - \mu_2 \begin{matrix} < \\ \neq \\ > \end{matrix} 0$$

Toetsingsgrootheid

$$T = \frac{\bar{X} - \bar{Y}}{\sqrt{S_1^2/n + S_2^2/m}}.$$

- Onder H_0 $T \sim t_\nu$
- ν kan geschat worden uit de data en is vaak $\approx n + m - 2$

De z -toets voor het verschil tussen normale populaties

- **Toetsingsgrootheid:**
$$T = \frac{\bar{X} - \bar{Y}}{\sqrt{S_1^2/n + S_2^2/m}}$$
- **p -waarde:**
 - ▶ Als $H_a : \mu_1 - \mu_2 \neq 0$, dan $2*(1-t.cdf(np.abs(t), df = n+m-2))$
 - ▶ Als $H_a : \mu_1 - \mu_2 < 0$, dan $t.cdf(t, df = n+m-2)$
 - ▶ Als $H_a : \mu_1 - \mu_2 > 0$, dan $1-t.cdf(t, df = n+m-2)$

Scenario 2: Normale populaties met onbekende varianties

De z -toets voor het verschil tussen normale populaties

- **Toetsingsgrootheid:** $T = \frac{\bar{X} - \bar{Y}}{\sqrt{S_1^2/n + S_2^2/m}}$
- **p -waarde:**
 - ▶ Als $H_a : \mu_1 - \mu_2 \neq 0$, dan $2*(1-t.cdf(np.abs(t), df = n+m-2))$
 - ▶ Als $H_a : \mu_1 - \mu_2 < 0$, dan $t.cdf(t, df = n+m-2)$
 - ▶ Als $H_a : \mu_1 - \mu_2 > 0$, dan $1-t.cdf(t, df = n+m-2)$

Betrouwbaarheidsinterval

Een $(1 - \alpha)100\%$ betrouwbaarheidsinterval voor $\mu_1 - \mu_2$ is

$$\bar{X} - \bar{Y} \pm t_{\alpha/2, n+m-2} \sqrt{S_1^2/n + S_2^2/m}$$

Verwerp ten faveure van $\mu_1 \neq \mu_2$ als deze 0 niet bevat!

Lezen jongens minder dan meisjes?

- 60 jongens lezen gemiddeld ≈ 18 minuten (st. deviatie ≈ 5)
- 70 meisjes lezen gemiddeld ≈ 20 minuten (st. deviatie ≈ 7)

Lezen jongens minder dan meisjes?

- 60 jongens lezen gemiddeld ≈ 18 minuten (st. deviatie ≈ 5)
- 70 meisjes lezen gemiddeld ≈ 20 minuten (st. deviatie ≈ 7)

❶ $H_0 : \mu_1 - \mu_2 \geq 0$ en $H_a : \mu_1 - \mu_2 < 0$

❷ Toetsingsgrootheid

$$t = \frac{\bar{x} - \bar{y}}{\sqrt{s_1^2/n + s_2^2/m}} = \frac{18 - 20}{\sqrt{5^2/60 + 7^2/70}} \approx -1.89$$

❸ $p\text{-waarde} = t.\text{cdf}(t, \text{df} = n+m-2) \approx 0.030$

❹ We verwerpen!

- Handmatig

- ▶ `xbar = np.mean(x) ; n = len(x) ; s1 = np.std(x, ddof = 1)`
- ▶ `ybar = np.mean(y) ; m = len(y) ; s2 = np.std(y, ddof = 1)`
- ▶ `tval = (xbar - ybar)/np.sqrt(s1**2/n + s2**2/m)`
- ▶ `p = t.cdf(tval, df = n+m-2)`

- Handmatig
 - ▶ `xbar = np.mean(x) ; n = len(x) ; s1 = np.std(x, ddof = 1)`
 - ▶ `ybar = np.mean(y) ; m = len(y) ; s2 = np.std(y, ddof = 1)`
 - ▶ `tval = (xbar - ybar)/np.sqrt(s1**2/n + s2**2/m)`
 - ▶ `p = t.cdf(tval, df = n+m-2)`
- `from scipy.stats import ttest_ind`
 - ▶ `ttest_ind(x, y, equal_var = False, alternative = "less")`

Scenario 3: Algemene populaties

Merk op

We gebruiken alleen normaliteit van $\bar{X}$. Gebruik de centrale limietstelling!

t-toets voor algemene data



De *t*-toets werkt ook voor algemene data, mits er maar voldoende (≥ 40) data in beide sets zit

1 Inferentie voor twee onafhankelijke steekproeven (9.1 en 9.2)

2 Inferentie voor een gepaarde steekproef (9.3).

Voorbeeld

Een cholesterolverlager wordt getest op 20 proefpersonen: Het cholesterolgehalte wordt gemeten zowel óór als ná het gebruik van het medicijn.



- De toets blijft hetzelfde:

$$H_0 : \mu_1 - \mu_2 = 0 \quad \text{tegen} \quad H_a : \mu_1 - \mu_2 \begin{matrix} < \\ \neq \\ > \end{matrix} 0$$

- Maak een nieuwe dataset $D_1, \dots, D_n$, met $D_i = X_i - Y_i$ en toets $\mathbb{E}(D_i) = 0$.
- Gebruik

$$T = \frac{\bar{D} - \mathbb{E}(\bar{D})}{\sqrt{\mathbb{V}(\bar{D})}}$$

- ▶ $\mathbb{E}(\bar{D}) = \mathbb{E}(\bar{X}) - \mathbb{E}(\bar{Y}) = \mu_1 - \mu_2$
- ▶ $\mathbb{V}(\bar{D}) = \frac{\mathbb{V}(D_i)}{n}$
- ▶ Wat is $\mathbb{V}(D_i) = \mathbb{V}(X_i - Y_i)$ wanneer X_i en Y_i *niet* onafhankelijk zijn?

Vraag: Hoe kwantificeren we afhankelijkheid van stochasten X en Y ?

Definitie: Covariantie

$$\text{Cov}(X, Y) = \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y)))$$

Vraag: Hoe kwantificeren we afhankelijkheid van stochasten X en Y ?

Definitie: Covariantie

$$\text{Cov}(X, Y) = \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y)))$$

Eigenschappen

- $\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$

Vraag: Hoe kwantificeren we afhankelijkheid van stochasten X en Y ?

Definitie: Covariantie

$$\text{Cov}(X, Y) = \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y)))$$

Eigenschappen

- $\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$
- Als X en Y onafhankelijk, dan $\text{Cov}(X, Y) = 0$.

Vraag: Hoe kwantificeren we afhankelijkheid van stochasten X en Y ?

Definitie: Covariantie

$$\text{Cov}(X, Y) = \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y)))$$

Eigenschappen

- $\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$
- Als X en Y onafhankelijk, dan $\text{Cov}(X, Y) = 0$.
 - ▶ Niet noodzakelijk andersom

Vraag: Hoe kwantificeren we afhankelijkheid van stochasten X en Y ?

Definitie: Covariantie

$$\text{Cov}(X, Y) = \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y)))$$

Eigenschappen

- $\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$
- Als X en Y onafhankelijk, dan $\text{Cov}(X, Y) = 0$.
 - ▶ Niet noodzakelijk andersom
- Als $\text{Cov}(X, Y) > 0$ (< 0) dan zijn X en Y *positief* (*negatief*) gecorreleerd en als $\text{Cov}(X, Y) = 0$ dan zijn X en Y ongecorreleerd

Vraag: Hoe kwantificeren we afhankelijkheid van stochasten X en Y ?

Definitie: Covariantie

$$\text{Cov}(X, Y) = \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y)))$$

Eigenschappen

- $\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$
- Als X en Y onafhankelijk, dan $\text{Cov}(X, Y) = 0$.
 - ▶ Niet noodzakelijk andersom
- Als $\text{Cov}(X, Y) > 0$ (< 0) dan zijn X en Y *positief* (*negatief*) gecorreleerd en als $\text{Cov}(X, Y) = 0$ dan zijn X en Y ongecorreleerd

Intermezzo: De correlatiecoëfficiënt

Vraag: Hoe kwantificeren we afhankelijkheid van stochasten X en Y ?

Definitie: Covariantie

$$\text{Cov}(X, Y) = \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y)))$$


Eigenschappen

- $\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$
- Als X en Y onafhankelijk, dan $\text{Cov}(X, Y) = 0$.
 - ▶ Niet noodzakelijk andersom
- Als $\text{Cov}(X, Y) > 0$ (< 0) dan zijn X en Y **positief** (**negatief**) gecorreleerd en als $\text{Cov}(X, Y) = 0$ dan zijn X en Y ongecorreleerd


Definitie: Correlatie

$$\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\mathbb{V}(X)\mathbb{V}(Y)}} \in [-1, 1]$$


Positief gecorreleerd




Negatief gecorreleerd



Ongecorreleerd



Ongecorreleerd



Herinner

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}(X))(Y - \mathbb{E}(Y))]$$

Herinner

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}(X))(Y - \mathbb{E}(Y))]$$

Stelling

- $\text{Cov}(X, X) = \mathbb{V}(X)$.

Herinner

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}(X))(Y - \mathbb{E}(Y))]$$

Stelling

- $\text{Cov}(X, X) = \mathbb{V}(X)$.
- $\text{Cov}(X, Y) = \text{Cov}(Y, X)$.

Herinner

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}(X))(Y - \mathbb{E}(Y))]$$

Stelling

- $\text{Cov}(X, X) = \mathbb{V}(X)$.
- $\text{Cov}(X, Y) = \text{Cov}(Y, X)$.
- $\text{Cov}(cX, Y) = c\text{Cov}(X, Y) = \text{Cov}(X, cY)$.

Herinner

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}(X))(Y - \mathbb{E}(Y))]$$

Stelling

- $\text{Cov}(X, X) = \mathbb{V}(X)$.
- $\text{Cov}(X, Y) = \text{Cov}(Y, X)$.
- $\text{Cov}(cX, Y) = c\text{Cov}(X, Y) = \text{Cov}(X, cY)$.
- $\text{Cov}(X + Z, Y) = \text{Cov}(X, Y) + \text{Cov}(Z, Y)$.

Herinner

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}(X))(Y - \mathbb{E}(Y))]$$

Stelling

- $\text{Cov}(X, X) = \mathbb{V}(X)$.
- $\text{Cov}(X, Y) = \text{Cov}(Y, X)$.
- $\text{Cov}(cX, Y) = c\text{Cov}(X, Y) = \text{Cov}(X, cY)$.
- $\text{Cov}(X + Z, Y) = \text{Cov}(X, Y) + \text{Cov}(Z, Y)$.

Herinner

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}(X))(Y - \mathbb{E}(Y))]$$

Stelling

- $\text{Cov}(X, X) = \mathbb{V}(X)$.
- $\text{Cov}(X, Y) = \text{Cov}(Y, X)$.
- $\text{Cov}(cX, Y) = c\text{Cov}(X, Y) = \text{Cov}(X, cY)$.
- $\text{Cov}(X + Z, Y) = \text{Cov}(X, Y) + \text{Cov}(Z, Y)$.

Gevolg

$$\mathbb{V}(X + Y) = \mathbb{V}(X) + \mathbb{V}(Y) + 2\text{Cov}(X, Y)$$

$$\mathbb{V}(X - Y) = \mathbb{V}(X) + \mathbb{V}(Y) - 2\text{Cov}(X, Y)$$

Eigenschap covariante

Voor twee stochasten X en Y ,

$$\mathbb{V}(X - Y) = \mathbb{V}(X) + \mathbb{V}(Y) - 2\text{Cov}(X, Y)$$

Eigenschap covariante

Voor twee stochasten X en Y ,

$$\mathbb{V}(X - Y) = \mathbb{V}(X) + \mathbb{V}(Y) - 2\text{Cov}(X, Y)$$

Gepaarde t -toets

We willen een toetsingsgrootheid van de vorm

$$\frac{\bar{X} - \bar{Y}}{\sqrt{\mathbb{V}(\bar{X} - \bar{Y})}}$$

- Bij onafhankelijke data: $\mathbb{V}(\bar{X} - \bar{Y}) = \frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{n}$.
- Nu $\mathbb{V}(\bar{X} - \bar{Y}) = \frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{n} - 2\sigma_X\sigma_Y\text{Corr}(X, Y)$

z -toets

- **Data:** $X_1, \dots, X_n \sim N(\mu_1, \sigma_1^2)$, $Y_1, \dots, Y_n \sim N(\mu_2, \sigma_2^2)$ gepaard met $\rho = \text{Corr}(X_i, Y_i)$, $i = 1, \dots, n$
- **Nulhypothese:** $H_0 : \mu_1 - \mu_2 = 0$.

- **Toetsingsgrootheid:**

$$Z = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{n} - \frac{2}{n}\sigma_1\sigma_2\rho}}$$

- **Onder H_0 :** $Z \sim N(0, 1)$.

t -toets

- **Data:** $X_1, \dots, X_n \sim N(\mu_1, \sigma_1^2)$, $Y_1, \dots, Y_n \sim N(\mu_2, \sigma_2^2)$ gepaard met $\rho = \text{Corr}(X_i, Y_i)$, $i = 1, \dots, n$
- **Nulhypothese:** $H_0 : \mu_1 - \mu_2 = 0$.

- **Toetsingsgrootheid:**

$$T = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{s_1^2}{n} + \frac{s_2^2}{n} - \frac{2}{n}s_1s_2\hat{\rho}}}$$

- **Onder H_0 :** $T \sim t_{2n-2}$

- Handmatig

- ▶ `xbar = np.mean(x) ; s1 = np.std(x, ddof = 1)`
- ▶ `ybar = np.mean(y) ; s2 = np.std(y, ddof = 1)`
- ▶ `n = len(x) ; rho = np.corrcoef(x, y)[0,1]`
- ▶ `tval = (xbar - ybar)/np.sqrt(s1**2/n + s2**2/n - (2/n)*s1*s2*rho)`
- ▶ `p = t.cdf(tval, df = 2*n-2)` *(afhankelijk van H_a)*

- Handmatig
 - ▶ `xbar = np.mean(x) ; s1 = np.std(x, ddof = 1)`
 - ▶ `ybar = np.mean(y) ; s2 = np.std(y, ddof = 1)`
 - ▶ `n = len(x) ; rho = np.corrcoef(x, y)[0,1]`
 - ▶ `tval = (xbar - ybar)/np.sqrt(s1**2/n + s2**2/n - (2/n)*s1*s2*rho)`
 - ▶ `p = t.cdf(tval, df = 2*n-2)` (afhankelijk van H_a)
- Zelfde effect (probeer zelf uit!)
 - ▶ `d = x-y`
 - ▶ `dbar = np.mean(d) ; n = len(d) ; s = np.std(d, ddof = 1)`
 - ▶ `tval = dbar/(s/np.sqrt(n))`
 - ▶ `p = t.cdf(tval, df = 2*n-2)`

- Handmatig
 - ▶ `xbar = np.mean(x) ; s1 = np.std(x, ddof = 1)`
 - ▶ `ybar = np.mean(y) ; s2 = np.std(y, ddof = 1)`
 - ▶ `n = len(x) ; rho = np.corrcoef(x, y)[0,1]`
 - ▶ `tval = (xbar - ybar)/np.sqrt(s1**2/n + s2**2/n - (2/n)*s1*s2*rho)`
 - ▶ `p = t.cdf(tval, df = 2*n-2)` (afhankelijk van H_a)
- Zelfde effect (probeer zelf uit!)
 - ▶ `d = x-y`
 - ▶ `dbar = np.mean(d) ; n = len(d) ; s = np.std(d, ddof = 1)`
 - ▶ `tval = dbar/(s/np.sqrt(n))`
 - ▶ `p = t.cdf(tval, df = 2*n-2)`
- `from scipy.stats import ttest_rel`
 - ▶ `ttest_rel(x, y, alternative = "less")`

- Onepaarde z toets en t -toets
- Gepaarde t -toets

Volgende les

- Enkelvoudige variantieanalyse