

Statistiek college 9


Variantieanalyse met één factor (10.1-10.3)

Marc Corstanje

8 Mei

- 1 De F -toets (10.1)
- 2 Tukey intervallen (10.2)
- 3 Het ANOVA model (10.3)

In een studie worden 30 proefpersonen gelijk verdeeld over drie condities (**nuchter**, **lage dosis cafeïne**, **hoge dosis cafeïne**) en wordt hun **reactietijd in ms** gemeten. *Kunnen we uit deze waarnemingen concluderen dat cafeïne de reactietijd beïnvloed?*




1 De F -toets (10.1)

2 Tukey intervallen (10.2)

3 Het ANOVA model (10.3)

- Er zijn in totaal N verschillende observaties
- Deze zijn onderverdeeld in I groepen
- Binnen elke groep n_i observaties
 - ▶ Dus $n_1 + \dots + n_I = N$
 - ▶ **Merk op:** in het boek $n_1 = \dots = n_I = J$
- **Nulhypothese:**
 $H_0 : \mu_1 = \dots \mu_I$




- We onderzoeken hoe de **responsvariabele** afhangt van de **verklarende variabele**
- De verklarende variabele is een **factor** en heeft I verschillende **levels**.
- Deze modellen worden ANOVA-modellen (Analysis of Variance) genoemd.

Voorbeelden

- **Factor:** “dosis cafeïne”
Levels: “geen”, “laag”, en “hoog”
Responsvariabele: reactietijd
- **Factor:** “merk paracetamol”
Levels: “Merk 1”, “Merk 2”, “Merk 3”, en “Merk 4”
Responsvariabele: mate van bijwerkingen
- **Factor:** “Opleiding”
Levels: “MNW”, “SBI”, en “FAR”
Responsvariabele: Cijfer voor Statistiek

Het idee achter de F -toets

- Komt de variatie door verschil in groepen of door variatie in de data?



- Beide datasets hebben dezelfde variantie.
 - ▶ Links komt de variatie door de verschillen tussen groepen
 - ▶ Rechts komt de variatie door andere zaken.
- Idee:** Vergelijk de variatie in de data, met de variatie tussen de groepen

- Notatie:

- ▶ $\bar{x}_{i.} = \frac{1}{n_i} \sum_{j=1}^{n_i} x_{ij}$ is het gemiddelde van de data binnen group i .
- ▶ $\bar{x}_{..} = \frac{1}{I} \sum_{i=1}^I \bar{x}_{i.}$ is het gemiddelde van alle data.

Kwadraatsommen

- De variantie *tussen* de groepen (*Treatment Sum of Squares*)

$$\text{SSTr} = \sum_{i=1}^I \sum_{j=1}^{n_i} (\bar{x}_{i.} - \bar{x}_{..})^2$$

- ▶ Hoeveel groepsgemiddelden van elkaar variëren

- De variantie *binnen* de groepen (*Error sum of squares*)

$$\text{SSE} = \sum_{i=1}^I \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_{i.})^2$$

- ▶ Hoeveel er binnen de groepen gevarieerd wordt.

Kwadratensommen

- $SSTr = \sum_{i=1}^I \sum_{j=1}^{n_i} (\bar{x}_{i.} - \bar{x}_{..})^2$ Treatment SS
- $SSE = \sum_{i=1}^I \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_{i.})^2$ Error SS
- $SST = \sum_{i=1}^I \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_{..})^2 = SSTr + SSE$ Total SS


MSEs: De gemiddelde fout

- $MSTr = SSTr / (I - 1)$
 - ▶ De gemiddelde fout door variatie tussen groepen
- $MSE = SSE / (N - I)$
 - ▶ De gemiddelde fout door variatie binnen groepen

Merk op: $MSTr \gg MSE$ is bewijs tegen de nulhypothese!


De F -toets voor ANOVA met één factor

- **Nulhypothese:** $H_0 : \mu_1 = \dots = \mu_I$
- **Toetsingsgrootheid:** $F = \frac{MSTr}{MSE}$
- **Verwerp** voor grote waarden van $F \implies p\text{-waarde} = \mathbb{P}(F_{I-1, N-I} \geq F)$
- Als de data binnen de groepen normaal is, geldt onder H_0 dat $F \sim F_{I-1, N-I}$
 - ▶ F_{ν_1, ν_2} is de **F -verdeling** met ν_1 vrijheidsgraden in de teller en ν_2 vrijheidsgraden in de noemer.



Opdracht 10.6

De hoeveelheid ijzer wordt gemeten in 4 soorten staal: carbonaat, silicaat, magnetiet, hematiet. Van elke soort worden 10 metingen gedaan. Kan geconcludeerd worden dat de verwachtingswaarden significant verschillen?



- Duidelijk is $N = 30$, $I = 4$ en $n_1 = n_2 = n_3 = n_4 = 10$.
- Uit de data bereken we
 - ▶ $\bar{x}_1 = 26.08$, $\bar{x}_2 = 24.69$,
 $\bar{x}_3 = 29.95$, $\bar{x}_4 = 33.84$,
 $\bar{x}_{..} = 28.64$
 - ▶ $SSTr \approx 509.12$ en $SSE \approx 563.213$
 - ▶ $MSTr \approx 169.71$ en $MSE \approx 15.64$
 - ▶ $F = \frac{MSTr}{MSE} \approx 10.85$

$$\begin{aligned} p\text{-waarde} &= P(F_{3,36} \geq 10.85) \\ &= 1 - \text{f.cdf}(10.85, 3, 36) \\ &\approx 3.20 \times 10^{-5} \end{aligned}$$

We verwerpen H_0 , er is sterk bewijs dat de groepen van elkaar verschillen.

- pandas DataFrame
- Rijen en kolommen (met naam)

	Reactietijd	Groep
0	205.609417	Hoge dosis
1	190.537078	Hoge dosis
2	203.931170	Hoge dosis
3	205.971171	Hoge dosis
4	199.210798	Hoge dosis

De F -toets in Python – handmatig

```
I = 3 ; N = len(df)
```

```
x1 = df.query('Groep == "Hoge dosis")["Reactietijd"] ; n1 = len(x1)
```

```
x2 = df.query('Groep == "Lage dosis")["Reactietijd"] ; n2 = len(x2)
```

```
x3 = df.query('Groep == "Nuchter")["Reactietijd"] ; n3 = len(x3)
```

```
xbar1 = np.mean(x1)
```

```
xbar2 = np.mean(x2)
```

```
xbar3 = np.mean(x3)
```

```
xbar = np.mean(df["Reactietijd"])
```

```
SSTr = n1*(xbar1-xbar)**2 + n2*(xbar2-xbar)**2 + n3*(xbar3-xbar)**2
```

```
SSE = np.sum((x1-xbar1)**2) + np.sum((x2-xbar2)**2) + np.sum((x3-xbar3)**2)
```

```
MSTr = SSTr/(I-1)
```

```
MSE = SSE/(N-I)
```

```
F = MSTr/MSE
```

```
p = 1 - f.cdf(F, dfn = I-1, dfd = N-I)
```

Optie 1

```
from scipy.stats import f_oneway  
f_oneway(x1, x2, x3)
```

Resultaat van f_oneway

```
F_onewayResult(statistic=10.849041258386109,  
pvalue=3.199045114130287e-05)
```

Optie 2 (Mijn aanbeveling)

```
import statsmodels.api as sm  
from statsmodels.formula.api import ols  
model = ols("ijzer ~ C(Soort)", data = irons).fit()  
sm.anova_lm(model, type = 1)
```

	df	sum_sq	mean_sq	F	PR(>F)
C(Soort)	3.0	509.122	169.707333	10.849041	0.000032
Residual	36.0	563.134	15.642611	NaN	NaN

1 De F -toets (10.1)

2 Tukey intervallen (10.2)

3 Het ANOVA model (10.3)

- Als H_0 wordt verworpen weten we dat $\mu_i \neq \mu_j$ voor zekere i en j maar welke?
- Bij paarsgewijs t -toetsen, hebben we een grotere kans op een Type 1 fout.

Tukey intervallen

Betrouwbaarheidsintervallen voor $\mu_i - \mu_j$ voor $i < j$ met een **gezamenlijk betrouwbaarheidsniveau** van $100(1 - \alpha)\%$ worden gegeven door

$$\bar{x}_i. - \bar{x}_j. \pm Q_{\alpha, I, N-I} \sqrt{\frac{\text{MSE}}{2} \left(\frac{1}{n_i} + \frac{1}{n_j} \right)}$$

waar $Q_{\alpha, I, N-I}$ de kritieke waarde is van de *studentized range verdeling* met parameters I en $N - I$.

Merk op: Als $n_i = n_j = J$, wordt de term onder de wortel simpelweg MSE/J

De paarsgewijze t -intervallen zijn kórtter dan de Tukey intervallen.

In Python:

```
scipy.stats.tukey_hsd(x1,x2,x3,x4)
```

```
Tukey intervals using scipy.stats.tukey_hsd:
Tukey's HSD Pairwise Group Comparisons (95.0% Confidence Interval)
Comparison  Statistic  p-value  Lower CI  Upper CI
(0 - 1)      1.390     0.860   -3.374    6.154
(0 - 2)     -3.870     0.146   -8.634    0.894
(0 - 3)     -7.760     0.001  -12.524   -2.996
(1 - 0)     -1.390     0.860   -6.154    3.374
(1 - 2)     -5.260     0.026  -10.024   -0.496
(1 - 3)     -9.150     0.000  -13.914   -4.386
(2 - 0)      3.870     0.146   -0.894    8.634
(2 - 1)      5.260     0.026    0.496   10.024
(2 - 3)     -3.890     0.143   -8.654    0.874
(3 - 0)      7.760     0.001    2.996   12.524
(3 - 1)      9.150     0.000    4.386   13.914
(3 - 2)      3.890     0.143   -0.874    8.654
```

- `ttest_ind(x3,x2)`
 - ▶ `TtestResult(`
 `statistic=3.158818924281918,`
 `pvalue=0.00543222680386548,`
 `df=18.0)`

1 De F -toets (10.1)

2 Tukey intervallen (10.2)

3 Het ANOVA model (10.3)

De data $\{x_{ij}\}$ komt van stochasten

$$X_{ij} = \mu_i + \epsilon_{ij}$$

- μ_i is het gemiddelde binnen groep i
- $\epsilon_{ij} \sim N(0, \sigma^2)$ is de afwijking per datapunt van dat gemiddelde

Anders geformuleerd:

$$X_{ij} = \mu + \alpha_i + \epsilon_{ij}$$

- μ het gemiddelde van alle data
- α_i de afwijking van het gemiddelde binnen groep i van μ
 - ▶ $\alpha_i = \mu - \mu_i$
 - ▶ $\alpha_1 + \dots + \alpha_I = 0$

Het ANOVA model

$$X_{ij} = \mu + \alpha_i + \epsilon_{ij}$$

waar $\alpha_1 + \dots + \alpha_I = 0$ en $\epsilon_{ij} \sim N(0, \sigma^2)$ onafhankelijk.

- μ is het **totale effect** (gemiddelde van de data)
- α_i is het **treatment effect**
- Hypothese voor de F -toets is $H_0: \alpha_1 = \dots = \alpha_I = 0$.

- Het **ANOVA** model wordt gebruikt om een variabele X te verklaren met een **categorische variabele**
- $X_{ij} = \mu + \alpha_i + \epsilon_{ij}$
 - ▶ μ is het **totale effect** (gemiddelde van de data)
 - ▶ ϵ_i is het **treatment effect** van categorie i
 - ▶ $\epsilon_{ij} \sim N(0, \sigma^2)$ is de fout wanneer X_{ij} geschat wordt met $\mu + \alpha_i$.
 - ▶ **Aanname:** $\alpha_1 + \dots + \alpha_I = 0$
- De F -toets vergelijkt variantie om te toetsen of de categorische variabele significante invloed heeft op X
 - ▶ $H_0 : \alpha_1 = \dots = \alpha_I = 0$
 - ▶ $F = \frac{SSTr/(I-1)}{SSE/(N-I)}$, volgt onder H_0 een $F_{I-1, N-I}$ -verdeling

Volgende les

- Variantieanalyse, deel II
- Meervoudige variantieanalyse