

Statistiek college 10

Variantieanalyse met twee factoren (11.1-11.2)


Marc Corstanje

11 Mei 2026

1 Variantieanalyse zonder interacties (11.1)

2 Variantieanalyse met interacties (11.2)

Recap ANOVA



- Zit er significant verschil tussen de groepsgemiddelden?

Het ANOVA model

$$X_{ij} = \mu + \alpha_i + \epsilon_{ij}$$

waar $\alpha_1 + \dots + \alpha_I = 0$ en $\epsilon_{ij} \sim N(0, \sigma^2)$ onafhankelijk.

- μ is het **totale effect** (gemiddelde van de data)
- α_i is het **treatment effect**
- Hypothese voor de F -toets is $H_0: \alpha_1 = \dots = \alpha_I = 0$.

Uitvoering F -toets


$$\text{MSTr} = \frac{\text{SSTr}}{I - 1} = \frac{\sum_i \sum_j (\bar{x}_{i.} - \bar{x}_{..})^2}{I - 1}$$

$$\text{MSE} = \frac{\text{SSE}}{N - I} = \frac{\sum_i \sum_j (x_{ij} - \bar{x}_{i.})^2}{N - I}$$

$$F = \frac{\text{MSTr}}{\text{MSE}} \sim F_{I-1, N-I} \text{ (onder } H_0)$$

Voorbeeldvragen

- Wat is het effect van temperatuur en luchtvochtigheid op de oogst van maisplanten?
- Wat is het effect van geslacht (man/vrouw) op salarisverhoging na een promotie?
- Is een combinatie van medicatie en therapie effectief in het behandelen van angststoornissen?
- Wat is het effect van de corona-epidemie op verschillende economische sectoren?



- Hoeveel verdient een gemiddelde man na promotie?
- Is de salarisverhoging voor mannen groter dan voor vrouwen? → *interactie*

1 Variantieanalyse zonder interacties (11.1)

2 Variantieanalyse met interacties (11.2)

Waarnemingen van een afhankelijke variabele X_{ijk} die afhangt van twee factoren:

- **Factor A** wordt geïndexeerd door i en heeft I levels.
- **Factor B** wordt geïndexeerd door j en heeft J levels.


Voor iedere combinatie¹ (i, j) van levels zijn er n_{ij} onafhankelijke waarnemingen $X_{ij1}, \dots, X_{ijK}$.

Merk op: Het boek neemt $n_{ij} = K$ voor alle paren (i, j) .

¹Een combinatie van levels heet ook wel een *cel*.

Voorbeeldvragen (vervolg)

- X = oogst van maisplanten
 - ▶ Factor A: temperatuur (3 levels: 10C°, 14C°, 18C°)
 - ▶ Factor B: luchtvochtigheid (3 levels: 60%, 70% en 80%)
- X = salarisverhoging
 - ▶ Factor A: promotie (2 levels: voor/na)
 - ▶ Factor B: geslacht (2 levels: man/vrouw)
- X = sterkte van de stoornis
 - ▶ Factor A: medicatie (2 levels: niet/wel)
 - ▶ Factor B: therapie (2 levels: niet/wel)
- X = omzet
 - ▶ Factor A: tijd (2 levels: 2019/2020)
 - ▶ Factor B: sector (3 levels: restaurants, recreatie, sport)



- Is de promotie van invloed op het salaris?
- Is het geslacht van invloed op het salaris?

Twee-factor ANOVA model zonder interacties

Recap: het ANOVA model voor 1 factor

$$X_{ij} = \mu + \alpha_i + \epsilon_{ij}$$

waar $\alpha_1 + \dots + \alpha_I = 0$ en $\epsilon_{ij} \sim N(0, \sigma^2)$ onafhankelijk.

- μ is het **totale effect** (gemiddelde van de data)
- α_i is het **treatment effect**
- $\mu_i = \mu + \alpha_i$ is het gemiddelde binnen groep i van de factor
- Hypothese voor de F -toets is $H_0: \alpha_1 = \dots = \alpha_I = 0$.

Voeg een factor toe

Een tweede factor heeft levels $j = 1, \dots, J$.

$$X_{ijk} = \mu + \alpha_i + \beta_j + \epsilon_{ijk}$$


- $\mu + \alpha_i + \beta_j$ is het gemiddelde van de data binnen level i van factor A en level j van factor B .

$$X_{ijk} = \mu + \alpha_i + \beta_j + \epsilon_{ijk}$$

- Data x_{ijk} , $k = 1, \dots, n_{ij}$ voor groep i van Factor A en groep j van Factor B
- Gemiddeld $\mu_{ij} = \mu + \alpha_i + \beta_j$ in groepencombinatie i en j

In de praktijk

- $\mu \approx \bar{X}$
- $\mu_i \approx \bar{X}_{i..} \implies \alpha_i \approx \bar{X}_{i..} - \bar{X}$
- $\beta_j \approx \bar{X}_{.j.} - \bar{X}$



De kwadraatsommen

$$SSA = \sum_{i=1}^I \sum_{j=1}^J \sum_{k=1}^{n_{ij}} (\bar{x}_{i..} - \bar{x}_{...})^2 \quad \text{Variantie door factor A}$$

$$SSB = \sum_{i=1}^I \sum_{j=1}^J \sum_{k=1}^{n_{ij}} (\bar{x}_{.j.} - \bar{x}_{...})^2 \quad \text{Variantie door factor B}$$

$$SSE = SST - SSA - SSB \quad \text{Variantie niet verklaard}$$

$$SST = \sum_{i=1}^I \sum_{j=1}^J \sum_{k=1}^{n_{ij}} (x_{ijk} - \bar{x}_{...})^2 = SSA + SSB + SSE$$

Mean Squared Errors

$$MSA = \frac{SSA}{I - 1}$$

$$MSB = \frac{SSB}{J - 1}$$

$$MSE = \frac{SSE}{N - I - J + 1}$$

$$MST = \frac{SST}{N - 1}$$

De F -toets voor $H_0 : \alpha_1 = \dots = \alpha_I = 0$


- **Toetsingsgrootheid:** $F = \frac{MSA}{MSE}$
- **Verdeling onder H_0 :** $F_{I-1, N-I-J+1}$

```
import statsmodels.api as sm
from statsmodels.formula.api import ols
model = ols('Salaris C(Geslacht) + C(Promotie)', data = data).fit()
sm.stats.anova_lm(model, type = 2)
```

	df	sum_sq	mean_sq	F	PR(>F)
C(Geslacht)	1.0	6.517272e+06	6.517272e+06	75.055716	1.170174e-16
C(Promotie)	1.0	6.796091e+06	6.796091e+06	78.266714	2.995276e-17
Residual	397.0	3.447248e+07	8.683245e+04	NaN	NaN

1 Variantieanalyse zonder interacties (11.1)

2 Variantieanalyse met interacties (11.2)



- Deze grafiek bevat de gemiddelde lonen van mannen en vrouwen voor en na de promotie.
- De salarisverhoging lijkt voor mannen hoger dan voor vrouwen.

Twee-factor ANOVA model met interacties


Wat als binnen een groep van **Factor B** het effect van **Factor A** veel groter is?
Bijvoorbeeld

- Een medicijn heeft een grotere impact bij vrouwen dan bij mannen
- Het verschil in sociale contacten is onder ouderen voor groter na corona





ANOVA met interacties

$$X_{ijk} = \mu + \alpha_i + \beta_j + \gamma_{ij} + \epsilon_{ijk}$$

- μ , α_i en β_j zoals voorheen.
- γ_{ij} is de **interactie** tussen **Factor A** en **Factor B**
- Gemiddelde binnen cel (i, j) : $\mu + \alpha_i + \beta_j + \gamma_{ij}$
- $\sum_{j=1}^J \gamma_{ij} = 0$ voor elke i en $\sum_{i=1}^I \gamma_{ij} = 0$ voor elke j



Interactieplots (2 levels per factor)



$$X_{ijk} = \mu + \alpha_i + \beta_j + \gamma_{ij} + \epsilon_{ijk}$$

Schatters

Gemiddelde groep i van A en j van B : $\hat{\mu} + \hat{\alpha}_i + \hat{\beta}_j + \hat{\gamma}_{ij} = \bar{X}_{ij}$.

We kunnen dan drie hypothesen toetsen.

Hypothesen

- ❶ $H_{0A}: \alpha_1 = \dots = \alpha_I = 0$ (geen hoofdeffect van Factor A)
- ❷ $H_{0B}: \beta_1 = \dots = \beta_I = 0$ (geen hoofdeffect van Factor B)
- ❸ $H_{0AB}: \gamma_{ij} = 0$ voor alle i en j (geen interactie effect)

$$SST = SSA + SSB + SSAB + SSE$$

Kwadratensommen

- $SST = \sum_{ijk} (X_{ijk} - \bar{X}_{...})^2$ Total SS ($N - 1$)
- $SSA = \sum_{ijk} (\bar{X}_{i..} - \bar{X}_{...})^2$ SS Factor A ($I - 1$)
- $SSB = \sum_{ijk} (\bar{X}_{.j.} - \bar{X}_{...})^2$ SS Factor B ($J - 1$)
- $SSAB = \sum_{ijk} (\bar{X}_{ij.} - \bar{X}_{i..} - \bar{X}_{.j.} + \bar{X}_{...})^2$ Interactie SS ($(I - 1)(J - 1)$)
- $SSE = \sum_{ijk} (X_{ijk} - \bar{X}_{ij.})^2$ Error SS ($N - IJ$)

F-toetsen voor hoofd- en interactie effecten

Toetsingsgrootheid voor H_{0A} :

$$F_A = \frac{SSA/(I-1)}{SSE/(N-IJ)} = \frac{MSA}{MSE} \sim F_{I-1, N-IJ}$$

Toetsingsgrootheid voor H_{0B} :

$$F_B = \frac{SSB/(J-1)}{SSE/(N-IJ)} = \frac{MSB}{MSE} \sim F_{J-1, N-IJ}$$

Toetsingsgrootheid voor H_{0AB} :

$$F_{AB} = \frac{SSAB/(I-1)(J-1)}{SSE/(N-IJ)} = \frac{MSAB}{MSE} \sim F_{(I-1)(J-1), N-IJ}$$


```
import statsmodels.api as sm
from statsmodels.formula.api import ols
model = ols('Salaris ~ C(Geslacht) * C(Promotie)', data = data).fit()
sm.stats.anova_lm(model, type = 2)
```

	df	sum_sq	mean_sq	F	PR(>F)
C(Geslacht)	1.0	6.517272e+06	6.517272e+06	77.975455	3.414518e-17
C(Promotie)	1.0	6.796091e+06	6.796091e+06	81.311363	8.372934e-18
C(Geslacht):C(Promotie)	1.0	1.374380e+06	1.374380e+06	16.443675	6.036474e-05
Residual	396.0	3.309810e+07	8.358107e+04	NaN	NaN

```
model.summary()
```

- Bevat een hoop informatie
- Let op de kolom coef

	coef
Intercept	3244.7183
C(Geslacht) [T.Vrouw]	-372.5234
C(Promotie) [T.Voor]	-377.9271
C(Geslacht) [T.Vrouw] : C(Promotie) [T.Voor]	234.4679

Gemiddelden

	Man	Vrouw
Na	3244.7183	3244.7183-372.5234
Voor	3244.7183-377.9271	3244.7183-372.5234-377.9271+234.4679

- Factoren toevoegen in ANOVA
 - ▶ Zonder interactie
 - ▶ Met interactie
- De F toets werkt hetzelfde
 - ▶ Vergelijk de variantie verklaard door waar je op toets met de variantie niet verklaard door het gehele model
 - ▶ Let op de vrijheidsgraden!

Volgende les

- Start lineaire regressie