

Statistiek college 11

Enkelvoudige lineaire regressie (12.1-12.3)


Marc Corstanje

13 Mei 2026

- 1 Het enkelvoudige lineaire regressiemodel
- 2 Punt-schaters voor de model parameters
- 3 De kwaliteit van de regressie
- 4 Statistische toetsen

- Beiden zijn voor *relaties tussen variabelen*
 - ▶ Responsvariabele en verklarende variabelen
- ANOVA voor categorische verklarende variabelen; factoren
 - ▶ man/vrouw, duur/goedkoop, Type A/Type B/Type C, etc.
 - ▶ Hoe beïnvloed een categorische verklarende variabele een numerieke responsvariabele?
- Regressie bij numerieke verklarende variabelen
 - ▶ inkomen, leeftijd, winst, temperatuur, etc.
 - ▶ Hoe beïnvloed een numerieke variabele een numerieke responsvariabele?

Onderzoek het verband tussen de toegediende dosis en de concentratie in het bloed



1 Het enkelvoudige lineaire regressiemodel

2 Punt-schaters voor de model parameters

3 De kwaliteit van de regressie

4 Statistische toetsen

- Kan historische data ons helpen toekomstige data te voorspellen?
- Begrijpen hoe de afhankelijkheid eruit ziet bij gepaarde data
- Eerste stap richting machine learning

Het eenvoudige lineaire regressiemodel

Een **getal** x is aan een **stochast** Y gerelateerd via

$$Y = \beta_0 + \beta_1 x + \epsilon$$

- We noemen Y de **responsvariabele** en x de **verklarende variabele**
- $\epsilon \sim N(0, \sigma^2)$ is de fout
- β_0 en β_1 zijn de **regressiecoëfficiënten**
- De lijn $y = \beta_0 + \beta_1 x$ heet de **regressielijn**

Voorbeeld


- $x = \text{Dosis}$ is bekend.
- Voorspel $Y = \text{Concentratie}$ via

$$\hat{y} = \beta_0 + \beta_1 x$$

- De fout die we maken is $e = y - \hat{y}$


Scatterplots

Sterk en positief




$$\beta_1 > 0, \sigma^2 \text{ klein}$$

Zwak en negatief



$$\beta_1 < 0, \sigma^2 \text{ groot}$$

Niet lineair



$$y = \beta_0 + \beta_1 x^2 + \epsilon ?$$

- 1 Het enkelvoudige lineaire regressiemodel
- 2 Punt-schaters voor de model parameters**
- 3 De kwaliteit van de regressie
- 4 Statistische toetsen

Het residu

Bij **gepaarde** data $(x_1, y_1), \dots, (x_n, y_n)$ is het totale residu (fout) van een schatting

$$f(\beta_0, \beta_1) = \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_i)]^2$$

Kleinste-kwadraten principe

- Neem $\hat{\beta}_0$ en $\hat{\beta}_1$ als de β_0 en β_1 waarvoor $f(\beta_0, \beta_1)$ minimaal is.
- $\hat{\beta}_0$ en $\hat{\beta}_1$ heten de **kleinste-kwadraten schatters**

Het minimaliseren van het residu geeft de **kleinste-kwadraten schatters** van β_0 en β_1 :

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{S_{xy}}{S_{xx}}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Relatie met correlatie

$$\hat{\beta}_1 = \text{corr}(Y_i, X_i) \frac{S_{yy}}{S_{xx}}$$

```
import numpy as np
import pandas as pd
import statsmodels.api as sm
from statsmodels.formula.api import ols
```

```
df.head(3)
```

	Concentration	Dose
0	6.143694	10.000000
1	34.687740	16.428571
2	35.258356	22.857143

```
model = ols('Concentration ~ Dose', data = df)
model.summary()
```


Dep. Variable:	Concentration		R-squared:	0.903			
Model:	OLS		Adj. R-squared:	0.896			
Method:	Least Squares		F-statistic:	121.6			
Date:	Thu, 23 Apr 2026		Prob (F-statistic):	5.73e-08			
Time:	17:18:24		Log-Likelihood:	-57.439			
No. Observations:	15		AIC:	118.9			
Df Residuals:	13		BIC:	120.3			
Df Model:	1						
Covariance Type:	nonrobust						
	coef	std err	t	P> t	[0.025	0.975]	
Intercept	1.5183	1.5183	6.853	0.222	0.828	-13.286	16.322
Dose	1.2262	1.2262	0.111	11.025	0.000	0.986	1.466
Omnibus:	0.119		Durbin-Watson:	2.654			
Prob(Omnibus):	0.942		Jarque-Bera (JB):	0.323			
Skew:	0.125		Prob(JB):	0.851			
Kurtosis:	2.326		Cond. No.	137.			

In Python: ols – de coëfficiënten en visualizatie

```
model.params[0]  
1.518265122386727
```

```
model.params[1]  
1.2262103243926212
```

```
import seaborn as sns  
sns.regplot(  
    data=df,  
    x="Dose",  
    y="Concentration",  
    ci = None,  
    line_kws = {"color": "red"}  
)  
plt.show()
```



- De parameters zijn geschat als $\hat{\beta}_0$ en $\hat{\beta}_1$
- Een nieuwe waarde x komt binnen
- De geschatte corresponderende y -waarde:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

- Gebruik

```
▶ newdata = pd.DataFrame({"Dose": [25]})  
▶ model.predict(newdata)  
0      32.173523
```

- Voor de gefitte waarden van binnen de data, gebruik

```
▶ model.predict()  
[13.78036837 21.66314902 29.54592968 37.42871034 45.31149099  
53.19427165 61.07705231 68.95983296 76.84261362 84.72539428 92.60817493  
100.49095559 108.37373625 116.2565169 124.13929756]
```

1 Het enkelvoudige lineaire regressiemodel

2 Punt-schaters voor de model parameters

3 De kwaliteit van de regressie

4 Statistische toetsen


Een enkelvoudig lineaire regressie model neemt aan dat er geldt dat

- ① $Y = \beta_0 + \beta_1 x + \epsilon$
- ② $\epsilon \sim N(0, \sigma^2)$
- ③ De verdeling van ϵ hangt niet van x af
- ④ ϵ is onafhankelijk van observaties

Dit betekent dat we op de volgende zaken moeten letten:


- De relatie tussen de x_i en y_i **moet** lineair zijn
- De variantie van ϵ **moet** constant zijn over alle x -waarden
- ϵ **moet** normaal verdeeld zijn
- ϵ **moet** onafhankelijk zijn van de waarde van x
- Uitschieters mogen het model niet teveel beïnvloeden

- De geschatte waarden zijn $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$
- De residuen zijn de fouten die we maken $e_i = y_i - \hat{y}_i$ en zijn realisaties van ϵ .



- Aannames 2, 3 en 4 controleren we via de residuen!
 - ▶ `model.resid`

Residuenanalyse – Residuenplots



- Gegeven data x , schatten we y met $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$.
- De totale variantie in de data

$$\text{SST} = \text{SSE} + \text{SSR}$$




Diagram illustrating the decomposition of the Total Sum of Squares (SST) into the Sum of Squares due to Error (SSE) and the Sum of Squares due to Regression (SSR):

- SST is labeled as **Totale variantie** $\sum (y_i - \bar{y})^2$.
- SSE is labeled as **Variantie door fouten in de regressie** $\sum (y_i - \hat{y}_i)^2$.
- SSR is labeled as **Variantie door de regressie** $\sum (\hat{y}_i - \bar{y})^2$.

- SSR is de *verklaarde variantie*
- SSE is de *onverklaarde variantie*
- **Determinatiecoëfficiënt:** $R^2 = \frac{\text{SSR}}{\text{SST}} = 1 - \frac{\text{SSE}}{\text{SST}}$

De determinatiecoëfficiënt

- **Determinatiecoëfficiënt:** $R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$
- Altijd tussen 0 en 1.
- R^2 representeert de hoeveelheid variantie die verklaart wordt het lineaire verband.



Dep. Variable:	Concentration	R-squared:	0.903	0.903
Model:	OLS	Adj. R-squared:	0.896	
Method:	Least Squares	F-statistic:	121.6	
Date:	Thu, 23 Apr 2026	Prob (F-statistic):	5.73e-08	
Time:	17:18:24	Log-Likelihood:	-57.439	
No. Observations:	15	AIC:	118.9	
Df Residuals:	13	BIC:	120.3	
Df Model:	1			
Covariance Type:	nonrobust			

	coef	std err	t	P> t	[0.025	0.975]
Intercept	1.5183	6.853	0.222	0.828	-13.286	16.322
Dose	1.2262	0.111	11.025	0.000	0.986	1.466

Omnibus:	0.119	Durbin-Watson:	2.654
Prob(Omnibus):	0.942	Jarque-Bera (JB):	0.323
Skew:	0.125	Prob(JB):	0.851
Kurtosis:	2.326	Cond. No.	137.

- 1 Het enkelvoudige lineaire regressiemodel
- 2 Punt-schaters voor de model parameters
- 3 De kwaliteit van de regressie
- 4 Statistische toetsen**

Toets voor de hellingsparameter β_1

Om te toetsen of de x -variabele significante invloed heeft op y , toetsen we

$$H_0 : \beta_1 = 0 \quad \text{tegen} \quad H_a : \beta_1 \neq 0$$

Stelling

$$\hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{S_{xx}}\right)$$

Gevolg

- $T = \frac{\hat{\beta}_1 - \beta_1}{S/\sqrt{S_{xx}}} \sim t_{n-2}$
 - ▶ Met S^2 een schatter voor σ^2
- Gebruik voor de hypothese de toetsingsgrootheid $T = \frac{\hat{\beta}_1}{S/\sqrt{S_{xx}}}$
- Een $100(1 - \alpha)\%$ betrouwbaarheidsinterval voor β_1 is $\hat{\beta}_1 \pm t_{\alpha/2, n-2} S/\sqrt{S_{xx}}$

Dep. Variable:	Concentration	R-squared:	0.903
Model:	OLS	Adj. R-squared:	0.896
Method:	Least Squares	F-statistic:	121.6
Date:	Thu, 23 Apr 2026	Prob (F-statistic):	5.73e-08
Time:	17:18:24	Log-Likelihood:	-57.439
No. Observations:	15	AIC:	118.9
Df Residuals:	13 13	BIC:	120.3
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025
Intercept	1.5183	6.853 6.853	0.222 0.222	0.828 0.828	-13.286 -13.286
Dose	1.2262	0.111 0.111	11.025 11.025	0.000 0.000	0.986 0.986
Omnibus:	0.119	Durbin-Watson:	2.654		
Prob(Omnibus):	0.942	Jarque-Bera (JB):	0.323		
Skew:	0.125	Prob(JB):	0.851		
Kurtosis:	2.326	Cond. No.	137.		

- Het **enkelvoudige lineaire regressiemodel** gaat uit van het verband

$$Y = \beta_0 + \beta_1 x + \epsilon$$

- ▶ β_0, β_1 zijn de **regressiecoëfficiënten**
- ▶ ϵ is de fout
- We vinden schatters $\hat{\beta}_0, \hat{\beta}_1$ voor β_0 en β_1 via de kleinste-kwadratenmethode.
- De modelaannames kunnen we controleren via de **residuen** $e_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)$
- De **R^2 -waarde** geeft een indicatie van de kwaliteit van de fit
- Om te toetsen of de x -variabele significant invloed heeft op de y -variabele, gebruiken we een t -toets.

Volgende les

- Meervoudige regressieanalyse
- Varianten op meervoudige regressie
- Interactie
- **Let op:** Volgende les is het laatste college, 20 mei behandelen we een oud tentamen