

Statistiek college 12

Meervoudige lineaire regressie

Marc Corstanje


18 Mei 2026

- 1 Meervoudige lineaire regressie (13.4)
- 2 Model diagnose (13.1)
- 3 Varianten op meervoudige regressie (13.2, 13.3)
- 4 Interactie

Recap: Lineaire regressie

Lineair regressiemodel

- $Y = \beta_0 + \beta_1 x + \epsilon$
- $\epsilon \sim N(0, \sigma^2)$ is de fout
- β_0 en β_1 zijn de **regressiecoëfficiënten**
- De lijn $y = \beta_0 + \beta_1 x$ heet de **regressielijn**



1 Meervoudige lineaire regressie (13.4)

2 Model diagnose (13.1)

3 Varianten op meervoudige regressie (13.2, 13.3)


4 Interactie

- Bekijk de (eerste 5 records van de) volgende dataset:

		mpg	cyl	disp	hp	drat	wt	qsec	vs	am	gear	carb
0	Mazda RX4	21.000000	6	160.000000	110	3.900000	2.620000	16.460000	0	1	4	4
1	Mazda RX4 Wag	21.000000	6	160.000000	110	3.900000	2.875000	17.020000	0	1	4	4
2	Datsun 710	22.800000	4	108.000000	93	3.850000	2.320000	18.610000	1	1	4	1
3	Hornet 4 Drive	21.400000	6	258.000000	110	3.080000	3.215000	19.440000	1	0	3	1
4	Hornet Sportabout	18.700000	8	360.000000	175	3.150000	3.440000	17.020000	0	0	3	2

- Hier staat
 - ▶ **mpg** voor het verbruik, **hp** voor het vermogen en **wt** voor het gewicht
 - ▶ We willen het verbruik schatten via het gewicht en het vermogen

Meervoudige lineaire regressie – Motivatie – Data inspectie



Meervoudige regressie

De observaties van de responsvariabele worden gemodelleerd als

$$\text{mpg}_i = \beta_0 + \beta_1 \text{hp}_i + \beta_2 \text{wt}_i + \epsilon_i$$

```
model = ols('mpg    hp + wt', data = df).fit()  
model.summary()
```

Verbruik van een auto schatten we met

$$\text{mpg} = 37.22727 - 0.03177 \times \text{hp} - 3.87783 \times \text{wt}$$

Dep. Variable:	mpg	R-squared:	0.827
Model:	OLS	Adj. R-squared:	0.815
Method:	Least Squares	F-statistic:	69.21
Date:	Fri, 24 Apr 2026	Prob (F-statistic):	9.11e-12
Time:	13:38:17	Log-Likelihood:	-74.326
No. Observations:	32	AIC:	154.7
Df Residuals:	29	BIC:	159.0
Df Model:	2		
Covariance Type:	nonrobust		


	coef	std err	t	P> t	[0.025	0.975]
Intercept	37.2273	1.599	23.285	0.000	33.957	40.497
hp	-0.0318	0.009	-3.519	0.001	-0.050	-0.013
wt	-3.8778	0.633	-6.129	0.000	-5.172	-2.584

Omnibus:	5.303	Durbin-Watson:	1.362
Prob(Omnibus):	0.071	Jarque-Bera (JB):	4.046
Skew:	0.855	Prob(JB):	0.132
Kurtosis:	3.332	Cond. No.	588.

Resultierend model

Verbruik van een auto schatten we met

$$\text{mpg} = 37.22727 - 0.03177 \times \text{hp} - 3.87783 \times \text{wt}$$




1 Meervoudige lineaire regressie (13.4)

2 **Model diagnose (13.1)**

3 Varianten op meervoudige regressie (13.2, 13.3)

4 Interactie




Gegeven een regressielijn $y = \hat{\beta}_0 + \hat{\beta}_1 x$, kunnen we controleren dat

- Een lineair verband het juiste model is
- De fouten $\epsilon \sim N(0, \sigma^2)$ (zonder kennis van de waarde van σ)

Eigenschappen van de residuen

Residuen

Schat y_i met $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$. Het residu (fout) is $e_i = y_i - \hat{y}_i$



Verdeling van de residuen

$$e_i \sim N \left(0, \sigma^2 \left(1 - \frac{1}{n} - \frac{(x_i - \bar{x})^2}{S_{xx}} \right) \right)$$

Gestandardiseerde residuen

Het i -de gestandardiseerde residue wordt genoteerd met e_i^* en is gedefinieerd door

$$e_i^* = e_i / s \sqrt{1 - \frac{1}{n} - \frac{(x_i - \bar{x})^2}{S_{xx}}}$$

De gestandardiseerde residuen $e_1^*, \dots, e_n^*$ worden gebruikt voor model diagnose.

- Als aan de modelvoorwaarden voldaan is, dan $e_i^* \sim N(0, 1)$.

Herhaling: De meervoudige determinatiecoëfficiënt

- Gegeven data x , schatten we y met $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x + \dots + \hat{\beta}_k x^k$.
- De totale variantie in de data

$$\text{SST} = \text{SSE} + \text{SSR}$$

Diagram illustrating the decomposition of the Total Sum of Squares (SST) into the Sum of Squares due to Error (SSE) and the Sum of Squares due to Regression (SSR):




- SST is labeled as "Totale variantie $\sum (y_i - \bar{y})^2$ ".
- SSE is labeled as "Variantie door fouten in de regressie $\sum (y_i - \hat{y}_i)^2$ ".
- SSR is labeled as "Variantie door de regressie $\sum (\hat{y}_i - \bar{y})^2$ ".

- SSR is de *verklaarde variantie*
- SSE is de *onverklaarde variantie*
- **Determinatiecoëfficiënt:** $R^2 = \frac{\text{SSR}}{\text{SST}} = 1 - \frac{\text{SSE}}{\text{SST}}$

Wat is een goed model?

Een goed model


- Verklaart de variantie in de responsvariabele
- Is eenvoudig
- Is interpreteerbaar
- Heeft voorspellend en generaliserend vermogen



De aangepaste meervoudige determinatiecoëfficiënt

Om een geschikte balans te vinden tussen een goede fit en complexiteit van een polynomiaal regressiemodel kan de **aangepaste determinatiecoëfficiënt** worden gebruikt:

$$R_a^2 = 1 - \frac{SSE/(n - (k + 1))}{SST/(n - 1)}$$



- 1 Meervoudige lineaire regressie (13.4)
- 2 Model diagnose (13.1)
- 3 Varianten op meervoudige regressie (13.2, 13.3)**
- 4 Interactie


Polynomiale regressie

Polynomiale regressie

Neem $x_1 = x$, $x_2 = x^2$, $x_3 = x^3$, ..., zodat

$$Y = \beta_0 + \beta_1 x + \beta_2 x^2 + \cdots + \beta_k x^k + \epsilon_i$$

```
model = ols(' y ~ x + I(x**2)', data = df)
```



Lineaire modellen

Een lineair model is lineair in de parameters $\beta_0, \beta_1, \dots, \beta_k$

Transformatie responsevariabele

Ook mogelijk is

$$\log(Y) = \beta_0 + \beta_1 x + \epsilon$$

Dan is

$$\hat{y} = e^{\hat{\beta}_0 + \hat{\beta}_1 x}$$


- 1 Meervoudige lineaire regressie (13.4)
- 2 Model diagnose (13.1)
- 3 Varianten op meervoudige regressie (13.2, 13.3)
- 4 Interactie**

Meervoudige regressie met interactie


De observaties van de responsvariabele worden gemodelleerd als

$$\text{mpg}_i = \beta_0 + \beta_1 \text{hp}_i + \beta_2 \text{wt}_i + \beta_3 \text{hp}_i \text{wt}_i + \epsilon_i$$

```
model = ols('mpg ~ hp * wt', data = df).fit()
```



Categorische variabelen



```
model = ols('flipper_lengt_mm ~ body_mass_g + species', data = df).fit()
```

Categorische variabelen – Volledige output `ols`

Dep. Variable:	flipper_length_mm	R-squared:	0.854
Model:	OLS	Adj. R-squared:	0.853
Method:	Least Squares	F-statistic:	659.4
Date:	Fri, 24 Apr 2026	Prob (F-statistic):	7.42e-141
Time:	15:30:21	Log-Likelihood:	-1059.7
No. Observations:	342	AIC:	2127.
Df Residuals:	338	BIC:	2143.
Df Model:	3		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
Intercept	158.8603	2.387	66.564	0.000	154.166	163.555
species[T.Chinstrap]	5.5974	0.788	7.101	0.000	4.047	7.148
species[T.Gentoo]	15.6775	1.091	14.374	0.000	13.532	17.823
body_mass_g	0.0084	0.001	13.255	0.000	0.007	0.010
Omnibus:	1.615	Durbin-Watson:	1.786			
Prob(Omnibus):	0.446	Jarque-Bera (JB):	1.352			
Skew:	-0.106	Prob(JB):	0.509			
Kurtosis:	3.223	Cond. No.	3.70e+04			

Categorische variabelen – regressievergelijking(en)

	coef	std err	t	P> t	[0.025	0.975]
Intercept	158.8603	2.387	66.564	0.000	154.166	163.555
species[T.Chinstrap]	5.5974	0.788	7.101	0.000	4.047	7.148
species[T.Gentoo]	15.6775	1.091	14.374	0.000	13.532	17.823
body_mass_g	0.0084	0.001	13.255	0.000	0.007	0.010

Regressievergelijkingen

Laat $y = \text{flipper_length_mm}$ en $x = \text{body_mass_g}$

- Voor Adelie penguins

$$y = 158.8603 + 0.0084 \times x$$


- Voor Chinstrap penguins

$$y = 158.8603 + 5.5974 + 0.0084 \times x$$

- Voor Gentoo penguins

$$y = 158.8603 + 17.823 + 0.0084 \times x$$

Categorische variabelen – model zonder interactie



Categorische variabelen – model met interacties

```
model = ols('flipper_lengt_mm ~ body_mass_g * species', data = df).fit()
```


	coef	std err	t	P> t	[0.025
Intercept	165.2448	3.551	46.536	0.000	158.260
species[T.Chinstrap]	-13.8639	7.301	-1.899	0.058	-28.226
species[T.Gentoo]	6.0594	6.051	1.001	0.317	-5.843
body_mass_g	0.0067	0.001	7.011	0.000	0.005
body_mass_g:species[T.Chinstrap]	0.0052	0.002	2.683	0.008	0.001
body_mass_g:species[T.Gentoo]	0.0024	0.001	1.746	0.082	-0.000

Regressievergelijkingen

Laat $y = \text{flipper_length_mm}$ en $x = \text{body_mass_g}$

- Voor Adelie penguins: $y = 158.260 + 0.0067 \times x$
- Voor Chinstrap penguins: $y = 158.260 - 13.8639 + (0.0067 + 0.0052) \times x$
- Voor Gentoo penguins: $y = 158.260 + 6.0594 + (0.0067 + 0.0024) \times x$

Categorische variabelen – model zonder interactie



- Veel is mogelijk met lineaire regressie, als het model maar lineair is in de parameters
 - ▶ Polynomiale regressie
 - ▶ Transformatie van de responsvariabele
 - ▶ Meervoudige regressie
- De aangepaste determinatiecoëfficiënt helpt modellen te vergelijken met verschillend aantal verklarende variabelen
- Interactie geeft weer hoe een variabele een andere variabele beïnvloed

Volgende les

- Er is geen volgende les!
- Woensdag 20 mei behandelen we een oud deeltentamen